

SOAL LATIHAN PERTEMUAN 5 NIM GANJIL

Prediksi Poin Akhir Klub dalam Satu Musim

Deskripsi Masalah

Sebuah klub sepak bola ingin mengidentifikasi metrik performa mana yang paling krusial untuk meraih poin terbanyak di akhir musim. Analisis ini akan menjadi panduan untuk:

- Menentukan strategi perekrutan pemain yang efektif
- Mengevaluasi efektivitas taktik tim
- Mengidentifikasi area yang perlu ditingkatkan untuk meraih posisi lebih tinggi di klasemen

Dataset

English Premier League (EPL) Results

- **Link:** <https://www.kaggle.com/datasets/irkaal/english-premier-league-results>
- **Deskripsi:** Data hasil pertandingan Premier League dari musim 1993-94 hingga 2021-22
- **Jumlah Data:** Lebih dari 10.000 pertandingan
- **Format :** results.csv

Tugas

A. Data Preparation & Preprocessing (Bobot: 25%)

1. **Tangani Missing Values**
Identifikasi kolom yang memiliki missing values. Tentukan strategi penanganan (hapus baris/kolom, imputasi dengan mean/median/modus).
2. **Encoding Data Kategorikal**
Identifikasi kolom dengan tipe data kategorikal. Lakukan encoding menggunakan metode yang sesuai (One-Hot Encoding atau Ordinal Encoding)
3. **Normalisasi Data**
Gunakan StandardScaler untuk menormalisasi data numerik.
4. **Train-Test Split (80-20)**
Bagi data menjadi training set (80%) dan testing set (20%). Gunakan random_state=42 untuk reproduksibilitas.

B. Analisis Data (Bobot: 25%)

1. Analisis Deskriptif
Tampilkan statistik deskriptif untuk setiap variabel numerik.
2. Visualisasi Data
Buat histogram untuk setiap variabel numerik. Buat boxplot untuk mengidentifikasi outlier. Buat scatter plot antara points dengan beberapa variabel independent. Buat heatmap korelasi antar variabel
3. Korelasi
Identifikasi 3 variabel yang paling berkorelasi dengan points.

C. Pemodelan (Bobot: 25%)

1. Membangun Model
2. Interpretasi Model
Tampilkan nilai intercept dan koefisien untuk setiap variable. Identifikasi 3 variabel dengan pengaruh terbesar terhadap poin
3. Analisis Model

D. Evaluasi Model (Bobot: 25%)

1. Metrik Evaluasi
Hitung R^2 Score (Koefisien Determinasi). Hitung MAE (Mean Absolute Error). Hitung RMSE (Root Mean Squared Error)
2. Visualisasi Hasil
Buat plot antara nilai aktual (y_{test}) vs nilai prediksi (y_{pred}). Buat plot residual ($y_{test} - y_{pred}$) untuk memeriksa asumsi regresi
3. Analisis Error
Identifikasi 3 prediksi dengan error terbesar (overprediction/underprediction)
4. Kesimpulan
Apakah model layak digunakan? Mengapa?. Apa rekomendasi untuk meningkatkan akurasi model?

Buat semua tugas diatas dalam satu file .ipynb, diberi Nama lengkap dan NIM lengkap kumpulkan di <https://forms.gle/7juM733PTrZnsZdw6> sesuai jadwal kelas masing-masing.